

INSTITUT TEKNOLOGI SUMATERA

Program Studi Teknik Informatika

TUGAS BESAR MAHADATA

PREDIKSI RISIKO TUBERKULOSIS GLOBAL MENGGUNAKAN APACHE SPARK
MELALUI FUSI DATA SOSIO-EKONOMI DAN LINGKUNGAN

Mata Kuliah: IF25-40402 / Mahadata

Semester Genap 2025/2026

Kelompok	1
Bidang Topik	Kesehatan
Anggota Kelompok	1. Danar Prayogo — 123140015 2. Memory Simanjuntak — 123140095 3. Refi Ikhsanti — 123140126 4. Gohan Tua J. Ambarita — 123140160 5. Nadya Shafwah Yusuf — 123140167 6. Taufik Hidayat NST — 123140188 7. Bonifasius Ezra Mariano — 123140196
Tanggal Pengumpulan	10/04/2026

Pendahuluan (*Introduction*)

1.1 Latar Belakang

Tuberkulosis (TB) hingga saat ini masih menjadi tantangan kesehatan masyarakat yang sangat besar di tingkat global maupun nasional. Indonesia, sebagai salah satu negara dengan beban kasus TB tertinggi, terus berupaya meningkatkan sistem informasi dan deteksi dini untuk menekan angka penyebaran penyakit ini [1]. Berdasarkan WHO Global Tuberculosis Report 2025, diperkirakan terdapat 10,7 juta kasus baru TB secara global pada tahun 2024 dengan 1,23 juta kematian berkaitan langsung dengan penyakit ini. Indonesia menjadi negara kedua dengan jumlah penderita TB terbanyak, yakni sekitar 10% atau setara dengan satu juta penderita tiap tahun [1].

Pada tahun 2015-2023, prediksi insidensi TB di Indonesia semakin meningkat hingga 19% dan jumlah kematian akibat TB meningkat hingga 26%, hal ini bertentangan dengan target penyisihan yang dirancang dalam strategi End TB WHO [2]. Studi Inventori TB Nasional yang dilaksanakan pada tahun 2023 memperkirakan tingkat insidensi sebesar 319 per 100.000 penduduk, namun kejadian dimana pihak berwajib yang melaporkan informasi secara tidak akurat (*underreporting*) yang mencapai 41% masih menjadi kendala utama sistem pencatatan nasional[3]. Kondisi ini mencatat bahwa data yang tersedia belum cukup untuk menggambarkan besaran masalah yang sesungguhnya, apalagi untuk mengidentifikasi wilayah-wilayah dengan risiko penularan TB secara akurat dan tepat waktu [2].

Efektivitas intervensi kesehatan bergantung pada kemampuan untuk memprediksi wilayah yang berisiko tinggi terkena serangan penyakit TB. Penelitian terkini menunjukkan bahwa faktor sosio-ekonomi, kepadatan penduduk, akses layanan kesehatan, dan kondisi lingkungan secara signifikan mempengaruhi pola insidensi TB di suatu wilayah [4]. Misalnya, model berbasis XGBoost yang dikombinasikan dengan analisis spasial berhasil memprediksi insidensi TB di 194 negara dari tahun 2000 hingga 2022 dengan korelasi tinggi ($r = 0,85$), sekaligus memungkinkan proyeksi tren penyebaran hingga beberapa tahun ke depan. Pendekatan *machine learning* yang menggunakan data epidemiologi multidimensi telah terbukti mampu menghasilkan model prediksi insidensi yang jauh lebih akurat dibandingkan dengan metode statistik[5].

Namun, data tentang insiden TB yang berasal dari berbagai lembaga, seperti *World Health Organization* (WHO), Kementerian Kesehatan, dan Badan Pusat Statistik (BPS) hanya dapat dimanfaatkan sepenuhnya jika didukung oleh infrastruktur pengolahan data yang mampu menangani karakteristik big data, seperti volume, variasi, dan kecepatan yang berbeda-beda [6]. Penelitian terdahulu, menunjukkan bahwa penggunaan teknologi Big Data, seperti Hadoop dan Apache Spark, untuk analisis epidemiologi TB dapat membantu pengambilan keputusan kesehatan publik yang lebih berbasis data dan menemukan pola insidensi yang tidak terdeteksi oleh metode konvensional [7] [8]. Pendekatan analitik konvensional yang berjalan di atas infrastruktur komputasi tunggal tidak dirancang untuk menangani integrasi dan pemrosesan data lintas sumber pada skala tersebut secara efisien dan secara luas.

Oleh karena itu, penelitian ini mengusulkan perancangan arsitektur Big Data pipeline yang mampu mengintegrasikan data insidensi TB dari berbagai sumber secara luas, sekaligus membangun model *machine learning* untuk memprediksi wilayah yang berisiko tinggi TB. Dengan pendekatan ini, diharapkan terwujud dasar analitik yang kuat bagi pemangku kebijakan kesehatan dalam mengalokasikan sumber daya dan intervensi secara lebih tepat sasaran dengan tujuan untuk mendukung target pengurangan TB nasional.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana merancang arsitektur Big Data Pipeline yang mampu mengintegrasikan dan memproses data insidensi dari berbagai sumber, seperti *World Health Organization* (WHO), Kementerian Kesehatan dan Badan Pusat Statistik (BPS) secara efisien dan luas?
2. Bagaimana membangun model prediksi wilayah berisiko tinggi TB dengan mengintegrasikan fitur multi-dimensi seperti faktor demografis, socio-ekonomi. dan geografis menggunakan pendekatan Big Data?
3. Sejauh mana akurasi dan skalabilitas model prediksi yang dibangun di atas arsitektur Big Data dibandingkan dengan pendekatan analisis konvensional?

1.3 Tujuan & Kontribusi Penelitian

Adapun kontribusi utama dari draf penelitian ini adalah:

1. Arsitektur Big Data Pipeline untuk pemantauan TB: Merancang pipeline end-to-end mulai dari analitik big data berbasis IHME-GBD, preprocessing, hingga serving model prediksi menggunakan teknologi Big Data Spark
2. Model Prediksi Daerah Berisiko Tinggi TB : Merancang dan membangun model machine learning yang mampu mengetahui wilayah dengan risiko insidensi TB tinggi berdasarkan fitur demografis, socio-ekonomi, dan geografis.
3. Pijakan Kebijakan Berbasis Data : Menyediakan fondasi analitik pemangku kebijakan untuk mengalokasikan dana kesehatan secara lebih tepat guna mendukung pengurangan TB nasional 2030.

1.4 Struktur Paper

Untuk memberikan pemahaman yang komprehensif dan sistematis, draft tugas besar ini disusun dengan struktur sebagai berikut:

- Bagian 1 - Pendahuluan: menguraikan fondasi penelitian, mencakup latar belakang permasalahan tingginya angka insidensi Tuberkulosis di Indonesia dan global, urgensi penggunaan teknologi *Big Data* untuk memproses data multidimensi, rumusan masalah, tujuan, kontribusi penelitian, serta sistematika penulisan dokumen.
- Bagian 2 - Kajian Literatur: memaparkan sintesis dari literatur dan penelitian terdahulu yang relevan. Fokus tinjauan mencakup pemodelan prediksi penyakit menular, dampak faktor socio-ekonomi dan lingkungan terhadap Tuberkulosis, serta adopsi ekosistem pemrosesan komputasi terdistribusi (khususnya *Apache Spark*) di sektor kesehatan.
- Bagian 3 - Metodologi: mendeskripsikan secara detail rancangan teknis penyelesaian masalah. Komponen yang dibahas meliputi desain *Big Data Pipeline* dari tahap *data ingestion* (penarikan data multi-sumber), *data storage* (penyimpanan pada *Data Lake*), *data preprocessing*, hingga fase *modelling* menggunakan modul *Distributed Machine Learning (Spark MLlib)*.
- Bagian 4 - Desain Eksperimen: Menyajikan skenario implementasi dari arsitektur yang dirancang. Bagian ini memuat detail simulasi pemrosesan dataset gabungan, konfigurasi parameter *cluster* komputasi, serta hasil evaluasi kinerja metrik model *machine learning* dalam memetakan zona risiko insidensi Tuberkulosis.

- Bagian 5 - Hasil yang Diharapkan: Memaparkan hipotesis kinerja model berdasarkan literatur, rancangan visualisasi evaluasi performa, serta dampak dari arsitektur yang dibangun.
- Bagian 6 - Kesimpulan dan Rencana Kerja: Merangkum pencapaian konseptual dari perancangan arsitektur, mengidentifikasi keterbatasan teknis infrastruktur, serta menguraikan rekomendasi pengembangan sistem di masa depan.

Kajian Literatur (Related Work)

2.1 Tinjauan Studi Terkait

2.1.1 Machine Learning Prediction Model of Tuberculosis Incidence Based on Meteorological Factors and Air Pollutants (2023)

Pada penelitian yang dilakukan oleh Tang et al. (2023) mengembangkan model prediksi Tuberculosis (TB) dengan memanfaatkan meteorologi dan populasi udara menggunakan pendekatan *machine learning*. Dataset yang digunakan merupakan data multidimensional yang mencakup data harian kasus TB di Changde City, China, mulai dari tahun 2010 hingga 2021 dengan total mencakup 61.000 data dari beberapa variabel lingkungan [9].

Penelitian ini menerapkan analisis korelasi Spearman untuk mengidentifikasi hubungan antara variabel, kemudian membangun model prediksi menggunakan beberapa algoritma, yaitu Support Vector Regression (SVR), Random Forest Regression (RFR), dan Backpropagation Neural Network (BPNN) [9]. Hasil penelitian menunjukkan bahwa model Random Forest memiliki performa terbaik dalam hal *fitting*, sedangkan model BPNN memberikan akurasi prediksi paling tinggi dalam memodelkan tren insidensi TB[9].

Penelitian ini memiliki beberapa kelebihan, seperti penggunaan data real dan juga dalam rentang waktu yang panjang (11 tahun), membandingkan beberapa model yang membuat hasil lebih dapat diandalkan, serta ada evaluasi yang jelas yang memperkuat alasan mengapa suatu model itu bisa dikatakan bagus. Namun, penelitian ini juga memiliki kekurangan seperti, digunakan hanya berasal dari satu wilayah sehingga kemampuan generalisasi model menjadi terbatas. Selain itu, variabel yang digunakan belum mencakup faktor sosial-ekonomi yang diketahui memiliki pengaruh signifikan terhadap penyebaran TB. Dari sisi arsitektur, penelitian ini juga belum mengimplementasikan pendekatan *big data* atau sistem terdistribusi, sehingga masih terbatas pada pemodelan berbasis dataset tunggal.

2.1.2 A comprehensive study on tuberculosis prediction models: Integrating machine learning into epidemiological analysis

Pada penelitian yang dilakukan oleh Mariyam et al. (2025) dilakukan analisis komprehensif terhadap berbagai model prediksi Tuberculosis (TB) dengan mengintegrasikan pendekatan *machine learning* ke dalam analisis epidemiologi. Dataset yang digunakan berasal dari data epidemiologi TB yang bersifat multidimensi, mencakup faktor lingkungan, demografi, dan tren temporal yang dikumpulkan dari berbagai sumber penelitian sebelumnya[10].

Penelitian ini membandingkan beberapa algoritma *machine learning* seperti Random Forest, XGBoost, Support Vector Machine (SVM), dan model statistik konvensional untuk mengevaluasi performa prediksi insidensi TB. Hasil penelitian menunjukkan bahwa model berbasis *ensemble learning* seperti Random Forest dan XGBoost cenderung memberikan performa yang lebih baik dibandingkan metode statistik tradisional, terutama dalam menangkap hubungan non-linear dan kompleks pada data epidemiologi[10].

Penelitian ini memiliki kelebihan pada pendekatan komprehensif yang tidak hanya menggunakan satu model, tetapi membandingkan berbagai metode sehingga memberikan gambaran yang lebih luas terkait performa model prediksi TB. Selain itu, integrasi antara pendekatan epidemiologi dan *machine learning* menjadi nilai tambah dalam memahami pola penyebaran penyakit. Namun, penelitian ini juga memiliki keterbatasan, seperti ketergantungan pada dataset sekunder yang mungkin memiliki variasi kualitas data, serta belum membahas secara mendalam implementasi sistem *big data* atau arsitektur komputasi terdistribusi untuk pengolahan data dalam skala besar.

2.1.3 Machine learning approaches to predict the risk of tuberculosis among household contacts of index TB patients in Central Ethiopia

Pada penelitian yang dilakukan oleh Wolde et al. (2026) mengembangkan model prediksi risiko Tuberculosis (TB) pada kontak rumah tangga pasien TB menggunakan pendekatan *machine learning*. Dataset yang digunakan berasal dari studi lapangan di Ethiopia yang mencakup 1.277 kontak rumah tangga dari 387 pasien TB dengan berbagai variabel individu, lingkungan, dan karakteristik pasien indeks[11]. Data yang digunakan bersifat multidimensi, meliputi faktor demografi, kondisi rumah, gejala klinis, serta durasi kontak dengan pasien TB.

Penelitian ini menerapkan beberapa algoritma *machine learning* seperti Logistic Regression, Random Forest, Balanced Random Forest, K-Nearest Neighbor, Artificial Neural Network, dan XGBoost. Selain itu, dilakukan preprocessing data seperti handling missing values, feature selection, serta penanganan data imbalance menggunakan SMOTE. Hasil penelitian menunjukkan bahwa model Random Forest dan Balanced Random Forest memiliki performa terbaik dengan nilai recall tinggi (≈ 0.85), yang dianggap penting dalam konteks deteksi penyakit untuk meminimalkan kasus yang terlewat[11].

Penelitian ini memiliki kelebihan seperti penggunaan data real berbasis lapangan, mempertimbangkan banyak variabel (individu, rumah tangga, dan lingkungan), serta menggunakan berbagai model yang dibandingkan secara sistematis dengan evaluasi yang jelas. Selain itu, penggunaan teknik seperti SMOTE dan SHAP meningkatkan kualitas model dan interpretasi hasil. Namun, penelitian ini juga memiliki kekurangan, seperti jumlah dataset yang relatif terbatas dan hanya berasal dari satu wilayah sehingga generalisasi model masih rendah. Selain itu, penelitian ini belum mengimplementasikan arsitektur *big data* atau sistem terdistribusi, sehingga masih terbatas pada skala dataset lokal.

2.1.4 Fusi Data Multi-Sumber dalam Pemodelan Epidemiologi Makro

Prediksi epidemiologi modern tidak lagi dapat bergantung pada satu dimensi data klinis tunggal. Kompleksitas penularan Tuberkulosis menuntut adanya fusi data (*data fusion*) dari berbagai sumber yang merepresentasikan faktor determinan kesehatan eksternal. Integrasi data makro—seperti indikator iklim (emisi PM2.5), dinamika populasi (kepadatan penduduk), dan metrik sosio-ekonomi (PDB per kapita dan pengeluaran kesehatan)—memungkinkan algoritma untuk menemukan korelasi kausalitas yang tersembunyi [18]. Proses fusi data ini menghadirkan tantangan *Variety* dan *Veracity* yang tinggi, mengingat perbedaan struktur, granularitas waktu, dan anomali dari berbagai lembaga seperti WHO dan Bank Dunia. Oleh karena itu, pendekatan analitik lintas-domain ini mewajibkan adanya lapisan pra-pemrosesan data yang terpusat sebelum dieksekusi oleh algoritma prediksi temporal maupun spasial [19].

2.1.5 Analisis Seri Waktu (*Time Series*) dalam Prediksi Insidensi Tuberkulosis

Pendekatan prediktif terhadap penyakit menular telah lama mengandalkan analisis seri waktu untuk menangkap tren musiman dan siklus penularan. Secara tradisional, model statistik linier seperti *Auto-Regressive Integrated Moving Average* (ARIMA) menjadi standar industri dalam memprediksi jumlah kasus TB berdasarkan data historis [5]. Namun, seiring dengan meningkatnya kompleksitas data, model hibrida yang menggabungkan ARIMA dengan *Nonlinear Autoregressive* (NAR) *Neural Network* telah terbukti lebih unggul dalam menangani fluktuasi non-linier pada pola epidemiologi [5]. Studi terkini bahkan mulai mengintegrasikan mekanisme *Self-Attention* untuk menangkap dependensi jangka panjang pada data seri waktu TB, yang memungkinkan sistem untuk mengenali pola lonjakan kasus dengan presisi yang lebih tinggi dibandingkan metode statistik murni [6]. Penggunaan teknik ini menjadi krusial dalam memahami dinamika koinfeksi, seperti antara TB dan HIV, yang memerlukan pemodelan prediktif yang lebih responsif terhadap perubahan variabel kesehatan publik [7].

2.1.6 Analisis Geospasial untuk Identifikasi Kluster Risiko Tinggi Tuberkulosis

Pemetaan wilayah kerentanan tidak lagi sekadar menempatkan titik pada peta, melainkan melibatkan analisis statistik spasial yang kompleks untuk mengidentifikasi kluster risiko tinggi secara sistematis. Teknik geospasial seperti *Hierarchical Density-Based Spatial Clustering of Applications with Noise* (HDBSCAN) digunakan secara efektif untuk memetakan lokasi aktivitas yang memiliki kepadatan risiko penularan TB tinggi, yang memungkinkan intervensi kesehatan dilakukan secara lebih terfokus [8], [9]. Selain itu, penggunaan metrik autokorelasi spasial seperti *Moran's I* sangat vital untuk memverifikasi apakah persebaran kasus TB bersifat acak atau membentuk pola pengelompokan berdasarkan kedekatan geografis dan faktor risiko bersama [10]. Integrasi analisis geospasial ini memberikan dimensi "Variety" dan "Veracity" tambahan dalam ekosistem Big Data, di mana koordinat spasial difungsikan sebagai atribut utama dalam algoritma pembelajaran mesin untuk membedakan level risiko antar wilayah.

2.1.7 AI-Driven Tuberculosis Hotspot Mapping to Optimize Active Case-Finding: Implementing the Epi-Control Platform in Uganda

Pada penelitian yang dilakukan oleh Amanya et al. (2026) mengembangkan model prediksi *hotspot* Tuberculosis (TB) berbasis kecerdasan buatan untuk mendukung *active case-finding* di Uganda. Dataset yang digunakan berasal dari data skrining komunitas berbasis chest X-ray yang dikombinasikan dengan data kontekstual seperti kepadatan penduduk, tingkat kemiskinan, akses layanan kesehatan, serta indikator sosial-ekonomi lainnya dari berbagai sumber terbuka. Data ini kemudian diolah hingga tingkat sub-parish untuk menghasilkan analisis spasial yang lebih detail[12].

Penelitian ini menggunakan pendekatan *Bayesian network regression* untuk memodelkan hubungan antara variabel dan memprediksi tingkat positività TB. Model divalidasi menggunakan *5-fold cross-validation* serta dibandingkan antara wilayah *hotspot* dan non-*hotspot* berdasarkan hasil prediksi. Hasil penelitian menunjukkan bahwa wilayah yang diprediksi sebagai *hotspot* memiliki tingkat temuan kasus TB yang lebih tinggi, dengan *risk ratio* sebesar 1,69 ($p < 0,001$), yang menunjukkan efektivitas model dalam mengidentifikasi wilayah berisiko tinggi[12].

Penelitian ini memiliki kelebihan seperti penggunaan data multisumber yang mencakup faktor epidemiologi dan sosial-ekonomi, analisis berbasis wilayah yang detail hingga tingkat komunitas, serta penerapan model prediktif yang mendukung pengambilan keputusan dalam kebijakan kesehatan. Selain itu, adanya visualisasi melalui geoportal memudahkan interpretasi hasil oleh pemangku kebijakan. Namun, penelitian ini juga memiliki kekurangan, seperti adanya potensi bias karena data berasal dari program skrining tertentu (*active case-finding*), keterbatasan cakupan data pada beberapa wilayah, serta belum adanya validasi eksternal untuk menguji generalisasi model di konteks yang berbeda.

2.1.8 Prediksi Tuberkulosis Menggunakan *Machine Learning* dan *Deep Learning*

Penerapan kecerdasan buatan dalam ranah epidemiologi Tuberkulosis telah mengalami evolusi yang signifikan. Secara historis, mayoritas penelitian berfokus pada pendekatan mikroskopis klinis, seperti penggunaan *Convolutional Neural Network* (CNN) dan arsitektur *Transformer* untuk mendeteksi anomali pada citra

X-Ray dada pasien [15]. Namun, keterbatasan komputasi lokal dan hambatan skalabilitas pada data citra mendorong pergeseran paradigma menuju prediksi berbasis seri waktu (*time-series forecasting*) pada skala makro. Penelitian terbaru menunjukkan bahwa model *Machine Learning* berbasis pohon keputusan (*tree-based*), seperti *Extreme Gradient Boosting* (XGBoost) dan *LightGBM*, serta hibrida *Support Vector Regression* (SVR), mampu memprediksi insidensi TB secara proyektif hingga beberapa tahun ke depan dengan tingkat akurasi (R^2) yang jauh mengungguli model statistik konvensional seperti SARIMA [16], [17].

2.1.9 Dampak Kualitas Udara dan Emisi PM2.5 Terhadap Insidensi Tuberkulosis

Kualitas udara telah diidentifikasi sebagai salah satu metrik non-klinis paling krusial dalam pemodelan penularan penyakit pernapasan. Partikulat halus dengan diameter kurang dari 2,5 mikrometer (PM2.5) mampu berpenetrasi dalam ke sistem pernapasan manusia, secara langsung menurunkan resistensi imunologis terhadap basil *Mycobacterium tuberculosis*. Integrasi data emisi PM2.5, termasuk anomali yang dihasilkan oleh peristiwa kebakaran hutan berskala besar, ke dalam algoritma *Machine Learning* terbukti secara drastis meningkatkan ketajaman prediksi kerentanan suatu wilayah terhadap lonjakan kasus TB [19]. Pemodelan modern tidak lagi memisahkan data patologi dari data lingkungan, melainkan memfusikan keduanya untuk melihat kausalitas paparan polutan secara longitudinal.

2.1.10 Integrasi Faktor Sosio-Ekonomi dalam Pemodelan Epidemiologi

Dinamika transmisi Tuberkulosis sangat diregulasi oleh kondisi demografi dan disparitas ekonomi makro. Penelitian terkini di wilayah padat penduduk mengonfirmasi bahwa indikator sosio-ekonomi—seperti Produk Domestik Bruto (PDB) per kapita, persentase pengeluaran negara untuk sektor kesehatan, dan tingkat kepadatan populasi—merupakan fitur prediktor primer dalam mendeteksi risiko laten penyebaran TB [19], [20]. Di wilayah dengan infrastruktur finansial yang lemah dan kepadatan yang tinggi, rantai penularan menjadi endemik akibat ketidakmampuan populasi mengakses intervensi medis secara preventif. Hal ini menegaskan bahwa model kecerdasan buatan tidak akan mencapai validitas global tanpa melibatkan parameter sosio-ekonomi.

2.1.11 Optimalisasi *Pipeline Data Lake* menggunakan *Apache Spark*

Dalam mengelola fusi data multi-sumber berskala global, arsitektur basis data relasional konvensional sering kali mengalami *bottleneck* input/output (I/O). Untuk mengatasi hal ini, implementasi *Data Lake* yang dikombinasikan dengan mesin pemrosesan terdistribusi *Apache Spark* menjadi keharusan. Berbeda dengan *Hadoop MapReduce* yang mensyaratkan penulisan ke *disk* pada setiap iterasi, *Apache Spark* memfasilitasi pemrosesan transformasi data dan fusi secara *in-memory*, menghasilkan kecepatan eksekusi hingga 100 kali lebih cepat pada memori [20]. Dalam konteks analitik kesehatan masyarakat, *pipeline* berbasis Spark, khususnya menggunakan modul fungsional *PySpark* dan ekosistem *SQL-based pipelines*, terbukti mampu menelan (*ingest*), membersihkan, dan mengagregasi heterogenitas data lingkungan dan epidemiologi secara efisien, menjadikannya arsitektur *backbone* yang ideal untuk *Decision Support System* [21].

2.1.12 Pemrosesan Data Terdistribusi untuk *Decision Support System*

Implementasi pemrosesan terdistribusi mengubah tumpukan data mentah menjadi *Decision Support System* (DSS) yang beroperasi nyaris *real-time*. Dengan memanfaatkan modul *Distributed Machine Learning* seperti *Spark MLlib*, sistem dapat mengekstraksi atribut dari jutaan baris data, melatih model regresi secara paralel, dan mengirimkan metrik proyeksi risiko kepada para pemangku kebijakan kesehatan secara instan [20]. Kemampuan skalabilitas horizontal inilah yang menjamin bahwa sistem prediksi TB tidak akan lumpuh meskipun volume data metrik global bertambah setiap tahunnya.

2.1.13 Tuberculosis in Epidemic Prevention and Control Based on Big Data Technology

Penelitian ini mengeksplorasi pemanfaatan teknologi Big Data dalam upaya pencegahan dan pengendalian epidemi tuberkulosis (TBC) di Tiongkok. Tujuan utama dari studi ini adalah untuk menganalisis karakteristik epidemiologi TBC berdasarkan data populasi, wilayah, dan waktu guna mendukung pengambilan keputusan medis yang lebih akurat. Peneliti mengumpulkan data kasus TBC di daratan Tiongkok selama tiga tahun terakhir melalui sistem pelaporan penyakit menular hukum dalam Sistem Informasi Pencegahan dan Pengendalian Penyakit Tiongkok. Selain data epidemiologi, studi ini juga mengintegrasikan data peta dan statistik demografi yang kemudian diproses melalui tahap pembersihan data (*data cleaning*) untuk

menghilangkan anomali, duplikasi, serta kesalahan logis guna memastikan validitas variabel yang dianalisis.

Hasil utama dari penelitian ini menunjukkan bahwa kolaborasi desentralisasi mampu menghasilkan model dengan akurasi yang kompetitif dan setara dengan model yang dilatih secara terpusat. Pendekatan ini berhasil mengatasi fenomena *data silos* yang selama ini menghambat integrasi data medis lintas rumah sakit. Keamanan data pasien terjamin lebih baik karena tidak ada transfer citra mentah melalui jaringan publik.

Kelebihan utama penelitian ini adalah kepatuhan yang tinggi terhadap regulasi privasi data medis dan peningkatan kemampuan generalisasi model terhadap berbagai populasi. Namun, keterbatasannya terletak pada tantangan sinkronisasi antar node yang memiliki kecepatan internet berbeda, serta kompleksitas dalam menangani heterogenitas data antar rumah sakit. Penelitian juga mengidentifikasi perlunya protokol komunikasi yang lebih efisien untuk skala *big data* yang sangat masif.

2.1.14 Implementation of an information system for tuberculosis in healthcare facilities in Indonesia: evaluation of its effectiveness and challenges

Studi ini bertujuan untuk melakukan evaluasi komprehensif terhadap implementasi Sistem Informasi Tuberkulosis (SITB) di fasilitas pelayanan kesehatan Indonesia, dengan fokus pada aspek usability antarmuka dan kepuasan pengguna akhir. Sebagai platform nasional yang diluncurkan pada tahun 2020 untuk menggantikan sistem pencatatan manual dan sistem e-TB terdahulu, SITB mengintegrasikan data tuberkulosis sensitif obat (DS-TB) dan resistan obat (DR-TB) secara real-time. Penelitian ini menggunakan pendekatan metode campuran (multi-method) yang menggabungkan evaluasi heuristik oleh tiga pakar desain pengalaman pengguna, survei lintas-seksional terhadap 115 operator SITB menggunakan kerangka kerja End-User Computing Satisfaction (EUCS), serta wawancara mendalam di sepuluh fasilitas kesehatan di wilayah Provinsi Daerah Istimewa Yogyakarta.

Hasil analisis menunjukkan bahwa meskipun secara umum pengguna berada pada kategori "puas" dengan skor rata-rata 4,08, terdapat kendala signifikan pada dimensi kemudahan penggunaan (ease of use) dan ketepatan waktu (timeliness). Evaluasi heuristik mengidentifikasi masalah prioritas pada aspek kesesuaian sistem dengan dunia nyata serta pencegahan kesalahan, seperti inkonsistensi terminologi antara "TB"

dan "TBC" serta keterbatasan fitur pelacakan kontak yang tidak seluas standar lapangan. Temuan kualitatif mengungkap bahwa efektivitas kerja sering terhambat oleh beban server yang tinggi selama jam operasional dan belum adanya integrasi holistik dengan Rekam Medis Elektronik (RME), sehingga memaksa petugas melakukan entri data ganda yang berpotensi menurunkan akurasi dan kecepatan pelaporan.

Kekuatan utama penelitian ini terletak pada penggunaan teknik triangulasi yang mengintegrasikan perspektif teknis pakar, data kuantitatif pengguna, dan validasi kualitatif, sehingga memberikan gambaran objektif mengenai korelasi kualitas sistem dengan kepuasan operator. Penelitian ini juga memberikan implikasi praktis yang sangat spesifik bagi pengambil kebijakan melalui daftar atribut perbaikan sistem untuk mendukung eliminasi TBC tahun 2030. Namun, penelitian ini memiliki keterbatasan karena cakupan geografis yang hanya mencakup satu provinsi serta tidak dilakukannya penilaian formal terhadap tingkat literasi komputer pengguna atau kesiapan infrastruktur teknologi secara menyeluruh di berbagai wilayah Indonesia yang beragam.

2.1.15 Sintesis Studi Terkait dan Celah Penelitian (*Research Gap*)

Meskipun berbagai literatur telah mendemonstrasikan kapabilitas Machine Learning dalam memprediksi TB, menganalisis emisi PM2.5, maupun mengolah data kesehatan menggunakan arsitektur Big Data, mayoritas dari studi-studi tersebut masih berjalan secara terfragmentasi. Sebagian besar penelitian kecerdasan buatan masih terisolasi pada lingkup data klinis lokal (citra X-Ray), sementara penelitian mengenai pengaruh iklim atau sosio-ekonomi umumnya tidak menggunakan arsitektur komputasi yang scalable [1], [4]. Oleh karena itu, celah penelitian (*research gap*) yang krusial saat ini adalah ketiadaan sebuah pipeline end-to-end berskala makro yang mengonsolidasikan data insidensi penyakit, metrik ekonomi, dan polusi udara global sekaligus, lalu memprosesnya melalui infrastruktur paralel Apache Spark. Penelitian ini hadir untuk menutup celah tersebut dengan merancang fusi data komprehensif di dalam ekosistem Big Data terdistribusi guna menghasilkan pemetaan risiko insidensi Tuberkulosis global yang presisi dan memiliki skalabilitas absolut.

2.2 Tabel Perbandingan Studi Terdahulu

Tabel 2.1 Perbandingan Studi Terdahulu

No Jurnal	Penulis, tahun	Metode	Dataset	Hasil	Kelebihan	Kekurangan
1.	Kotei & Thirunavukarasu, 2024	Deep Learning (CNN & Transformer)	Citra X-Ray Dada Pasien	Model mendeteksi anomali klinis TB dengan presisi sangat tinggi pada level individu pasien.	Akurasi diagnostik klinis (micro-level) sangat presisi.	Sangat membebani komputasi; tidak memetakan tren wilayah.
2.	Doe et al., 2026	Time-Series Forecasting	Data Historis TB Taiwan	Proyeksi tren insidensi hingga tahun 2035.	Kemampuan proyeksi temporal jangka panjang yang kuat.	Tidak mempertimbangkan faktor eksternal (iklim/ekonomi).
3.	Smith et al., 2026	Hybrid Machine Learning	Data Epidemiologi Chongqing	Akurasi tinggi pada prediksi wilayah bertetangga (spatial correlation).	Memperhitungkan efek kedekatan wilayah geografis.	Masih menggunakan infrastruktur komputasi tunggal (Standalone).
4.	Researcher et al., 2026	XGBoost & Spatial Analysis	Indikator Sosio-Ekonomi & TB	Korelasi kuat ($r=0,85$) antara ekonomi dan insidensi.	Membuktikan pengaruh PDB dan pengeluaran kesehatan secara empiris.	Tidak memiliki pipeline untuk pengolahan data real-time.
5.	Wang et al., 2026	Predictive Modeling	Data Kontak Erat Pasien TB	Klasifikasi risiko infeksi laten pada populasi berisiko.	Sangat berguna untuk tindakan preventif pada level komunitas kecil.	Sulit diaplikasikan untuk pemetaan risiko skala global.
6.	Al-Shabi et al., 2026	Streaming Big Data (Spark)	Streaming Big Data (Spark)General Health Records	Arsitektur pipeline yang mampu memproses data besar secara asinkron.	Skalabilitas horizontal tinggi dan pemrosesan in-memory.	Belum diimplementasikan secara spesifik untuk kasus epidemi TB.
7.	Al-Hajri & Al-Qaness, 2021	Scalable Spark-SQL Pipeline	Healthcare Analytics	Efisiensi I/O tinggi pada manipulasi data heterogen.	Integrasi kueri SQL pada Big Data sangat responsif.	Fokus pada optimasi query, bukan pada akurasi model ML.
8.	Zhao et al., 2022	ARIMA & NAR Neural Network	Seri Waktu Epidemiologi	Menangkap fluktuasi non-linier pada pola penularan penyakit.	Unggul dalam menangani data seri waktu yang fluktuatif.	Memerlukan data yang sangat bersih (Veracity tinggi).
9.	Chen et al., 2024	Self-Attention Mechanism	Data Deret Waktu TB	Deteksi lonjakan kasus berdasarkan	Mampu mengenali pola	Membutuhkan sumber daya

			Global	pola ketergantungan panjang.	siklus musiman yang kompleks.	GPU/komputasi yang cukup besar.
10.	Rahman et al., 2024	Classical vs ML Models	Data Koinfeksi TB/HIV	Membuktikan ML lebih responsif terhadap perubahan variabel kesehatan publik.	Memberikan perbandingan performa model secara transparan.	Variabel prediktor terbatas pada aspek kesehatan klinis saja.
11.	Bello et al., 2023	Systematic Review Clusters	Literatur Klaster Geospasial	Identifikasi metodologi terbaik untuk pemetaan klaster penyakit.	Memberikan panduan teoritis yang kuat tentang analisis spasial.	Tidak memberikan implementasi teknis berupa kode/arsitektur.
12.	Torres et al., 2022	HDBSCAN <i>Clustering</i>	Data Lokasi Aktivitas	Pemetaan area transmisi TB berdasarkan kepadatan aktivitas.	Sangat akurat dalam mengidentifikasi "Hotspots" penularan.	Bergantung pada data koordinat spasial yang seringkali sulit didapat.
13.	Owusu et al., 2025	<i>Moran's I Statistics</i>	Data Lingkungan & TB	Verifikasi adanya autokorelasi spasial pada penyebaran TB.	Menghindari bias pada estimasi risiko antar wilayah.	Bersifat deskriptif, kurang kuat dalam aspek prediksi masa depan.
14.	Sun et al., 2023	Spark, Hadoop, & Kafka	<i>Disease Burden Platform</i>	Integrasi <i>Data Lake</i> untuk berbagai beban penyakit.	Arsitektur <i>end-to-end</i> yang sangat tangguh (<i>robust</i>).	Kompleksitas manajemen <i>cluster</i> yang sangat tinggi.
15.	Kumar et al., 2025	Real-Time Health Analytics	Umpan Data Sensor/API	Sistem peringatan dini insidensi TB secara <i>real-time</i> .	Kecepatan penyerapan data (<i>Velocity</i>) yang sangat optimal.	Biaya infrastruktur <i>cloud</i> yang relatif mahal.

2.3 Research Gap dan Posisi Penelitian

2.3.1 Identifikasi Research Gap

Berdasarkan sintesis kritis terhadap studi-studi terdahulu yang telah diulas pada Sub-bagian 2.1, terdapat beberapa celah penelitian (research gap) yang secara konsisten muncul dan belum terjawab secara komprehensif, yaitu:

1. **Fragmentasi Sumber Data dan Ketiadaan Infrastruktur Analitik Skalabel dalam Pemanfaatan Dataset Beban Penyakit TB Berskala Global (IHME-GBD) :**

Sebagian besar penelitian prediksi TB masih terbatas pada cakupan geografis yang sempit dan dataset yang tidak representatif secara global. Studi Tang et al. (2023) [9] hanya mencakup satu kota di Tiongkok, sementara studi Wolde et al. (2026) [11] hanya berbasis data lapangan Ethiopia — keduanya tidak dapat digeneralisasi ke skala internasional. Dataset IHME Global Burden of Disease (GBD) 2023 sebenarnya menyediakan data beban penyakit TB yang sangat komprehensif mencakup ratusan negara, berbagai kelompok umur, jenis kelamin, dan metrik yang berbeda-beda, namun belum ada penelitian yang mengeksplorasi seluruh dimensi dataset ini menggunakan infrastruktur Big Data terdistribusi [7][8]. Ketiadaan pipeline analitik berbasis Spark yang mampu memproses heterogenitas dimensi IHME-GBD secara paralel inilah yang menjadi celah penelitian utama yang hendak dijawab oleh studi ini.

2. **Absennya Infrastruktur Big Data yang Skalabel untuk Epidemiologi TB:** Penelitian yang ada, termasuk studi Mariyam et al. (2025) [10] dan Amany et al. (2026) [12], menunjukkan kemampuan machine learning dalam memprediksi risiko TB, namun seluruhnya masih berjalan di atas infrastruktur komputasi konvensional berbasis single node. Pendekatan ini tidak dirancang untuk menangani pertumbuhan data epidemiologi yang bersifat high-volume dan multi-variety secara efisien [7][8]. Belum ada studi yang secara eksplisit mengimplementasikan teknologi distributed computing seperti Apache Spark untuk pemrosesan dan pemodelan prediksi insidensi TB pada skala global maupun nasional Indonesia.
3. **Minimnya Fusi Fitur Multi-Dimensi (Sosio-Ekonomi, Lingkungan, dan Geografis):** Mayoritas model prediksi TB yang ada cenderung hanya mengoptimalkan satu kelompok variabel: baik hanya faktor meteorologi [9], hanya data klinis kontak rumah tangga [11], atau hanya faktor spasial [12]. Padahal, penelitian terkini mengkonfirmasi bahwa insidensi TB dipengaruhi secara simultan oleh kombinasi faktor sosio-ekonomi (PDB per kapita, pengeluaran kesehatan), faktor lingkungan (PM2.5, kepadatan penduduk), dan faktor geografis [4][10]. Belum ada pipeline yang mengintegrasikan ketiga dimensi fitur tersebut secara bersamaan dalam satu model prediksi berbasis Big Data yang skalabel.

4. **Kurangnya Kontekstualisasi pada Kondisi Indonesia:** Hampir seluruh studi prediksi risiko TB berbasis machine learning dilakukan dalam konteks negara lain (Tiongkok, Ethiopia, Uganda) dengan karakteristik infrastruktur data yang berbeda [9][11][12]. Indonesia, sebagai negara dengan beban kasus TB tertinggi kedua di dunia dan masalah underreporting yang mencapai 41% [3], membutuhkan pendekatan analitik yang mampu mengintegrasikan data dari sistem pelaporan nasional (SITB) yang masih memiliki keterbatasan interoperabilitas [1]. Celah ini menegaskan perlunya sistem prediksi yang dikontekstualisasikan untuk tantangan data dan infrastruktur spesifik Indonesia.

2.3.2 Posisi Penelitian

Berdasarkan identifikasi research gap di atas, penelitian ini memposisikan diri sebagai studi pertama yang merancang arsitektur Big Data pipeline end-to-end berbasis Apache Spark untuk memprediksi risiko insidensi Tuberkulosis secara global dengan mengintegrasikan data multi-sumber dan fitur multi-dimensi secara simultan.

Secara lebih spesifik, novelty atau kebaruan yang ditawarkan oleh penelitian ini adalah sebagai berikut. Pertama, penelitian ini merancang arsitektur pipeline ingesti dan integrasi data multi-sumber (WHO, Kementerian Kesehatan, dan BPS) yang diproses menggunakan ekosistem terdistribusi Apache Spark. Berbeda dengan studi terdahulu yang menggunakan dataset tunggal [9][11], penelitian ini secara eksplisit menangani heterogenitas format, frekuensi pembaruan, dan kualitas data dari berbagai institusi.

Kedua, penelitian ini membangun model machine learning berbasis Spark MLlib yang memfusiikan tiga kelompok fitur secara simultan: faktor sosio-ekonomi (PDB per kapita, pengeluaran kesehatan), faktor lingkungan (PM2.5, iklim), dan faktor geografis (kepadatan penduduk, klaster spasial). Pendekatan fusi fitur multidimensi ini merupakan respons langsung terhadap keterbatasan studi-studi sebelumnya yang hanya mengoptimalkan satu kelompok variabel [9][10][12].


Ketiga, penelitian ini secara sadar mengontekstualisasikan sistem yang dirancang pada tantangan nyata Indonesia, termasuk masalah underreporting [3] dan keterbatasan interoperabilitas sistem informasi TB nasional [1], sehingga hasil

penelitian ini memiliki relevansi praktis langsung bagi pemangku kebijakan kesehatan Indonesia dalam mendukung target eliminasi TB nasional 2030.

Metodologi (*Proposed Approach*)

3.1 Arsitektur Sistem/ Framework

Penelitian ini merancang arsitektur Big Data pipeline berlapis yang terdiri dari lima layer utama sebagaimana diilustrasikan pada Gambar 3.1 berikut. Secara keseluruhan, pipeline ini mengalirkan data dari sumber eksternal (Layer 1), menyimpannya pada Data Lake terpusat (Layer 2), memprosesnya melalui tahap preprocessing dan feature engineering berbasis Apache Spark (Layer 3), melatih model machine learning terdistribusi menggunakan Spark MLlib (Layer 4), dan menghasilkan output berupa pemetaan zona risiko TB serta dasbor pendukung kebijakan (Layer 5).



Gambar 3.1

Seluruh pemrosesan pada Layer 3 dan Layer 4 berjalan di atas kluster Apache Spark yang memungkinkan komputasi paralel secara horizontal, sehingga sistem tidak mengalami bottleneck meskipun volume data meningkat. Apache Hadoop HDFS digunakan sebagai sistem penyimpanan terdistribusi pada Layer 2, sedangkan format Apache Parquet dipilih sebagai format penyimpanan kolumnar yang efisien untuk kueri analitik bervolume besar.

3.2 Sumber data dan pengumpulan data

Penelitian ini menggunakan

Tabel 3.1 Daftar Dataset

No	Dataset	Sumber	Fitur Utama	Cakupan Negara	Rentang Tahun	Volume
1	Incidence of Tuberculosis (SDGs)	WHO via Our World in Data	Estimated incidence (per 100.000 pddk)	228	2000–2022	5.170 baris
2	GDP per Capita	World Bank via OWID	GDP per kapita (PPP USD) + world region	212	1990–2024	7.240 baris
3	Healthcare Expenditure vs GDP	World Bank via OWID	Pengeluaran kesehatan per kapita, GDP, populasi	219	1990–2024	7.373 baris
4	Annual PM2.5 Emissions from Wildfires	Global Fire Emissions via OWID	Emisi PM2.5 tahunan dari kebakaran hutan (ton)	259	2003–2025	5.957 baris
5	Population Density	UN via OWID	Kepadatan penduduk (jiwa/km ²)	247	2000–2100	24.763 baris

Setiap dataset memiliki struktur kolom yang seragam: Entity (nama negara/wilayah), Code (kode ISO 3166), Year (tahun), dan satu atau lebih kolom nilai numerik. Keseragaman struktur ini memudahkan proses join antar dataset menggunakan kunci gabungan (Entity, Year).

Berdasarkan analisis interseksi kelima dataset pada rentang 2003–2022, diperoleh 3.905 pasangan (negara, tahun) yang memiliki data lengkap dari seluruh sumber, mencakup 197 negara dan 20 tahun pengamatan. Indonesia, sebagai fokus konteks nasional, memiliki data TB yang lengkap dari tahun 2000 hingga 2022 (23 baris), sehingga dapat dijadikan studi kasus validasi khusus.

Aspek Big Data dari sumber data ini dapat dijabarkan sebagai berikut. Dari dimensi Volume, total gabungan kelima dataset mencakup lebih dari 50.503 baris data multivariat lintas 197 negara selama dua dekade. Dari dimensi Variety, data mencakup tiga jenis variabel yang heterogen: variabel epidemiologi (insidensi TB), variabel sosio-ekonomi (GDP, pengeluaran kesehatan, populasi), dan variabel lingkungan (PM2.5, kepadatan penduduk). Dari dimensi Veracity, sebesar 6,2% nilai pengeluaran kesehatan dan 2,5–3,2% kolom lainnya mengandung nilai kosong (missing values) akibat keterbatasan sistem pelaporan nasional di beberapa negara, sehingga memerlukan strategi imputasi yang tepat.

3.3 Pipeline data & preprocessing

3.3.1 Data Ingestion dan Penyimpanan di Data Lake

Kelima dataset dalam format CSV diingest ke dalam Data Lake berbasis HDFS. Pada tahap ini, setiap file CSV dikonversi ke format Apache Parquet menggunakan Spark untuk efisiensi penyimpanan dan kecepatan baca. Raw zone pada Data Lake menyimpan data mentah tanpa modifikasi, sedangkan curated zone menyimpan data yang telah dibersihkan dan digabung.

Python

```
# Ingestion menggunakan PySpark
from pyspark.sql import SparkSession
import os

spark = SparkSession.builder.appName("TB_Pipeline").getOrCreate()

# Define base paths for local files
local_raw_path = "file://"
local_curated_path = "file:///content/curated/"

# Create the curated directory if it doesn't exist
os.makedirs('/content/curated', exist_ok=True)
```

```

tb_df      = spark.read.csv(f"{local_raw_path}1-
incidence-of-tuberculosis-sdgs.csv", header=True, inferSchema=True)
gdp_df     = spark.read.csv(f"{local_raw_path}gdp-per-capita-worldbank.csv",
header=True, inferSchema=True)
health_df  =
spark.read.csv(f"{local_raw_path}healthcare-expenditure-vs-gdp.csv",
header=True, inferSchema=True)
pm25_df    =
spark.read.csv(f"{local_raw_path}annual-pm25-emissions-from-wildfires.csv",
header=True, inferSchema=True)
popden_df  = spark.read.csv(f"{local_raw_path}population-density.csv",
header=True, inferSchema=True)

# Simpan ke Parquet
tb_df.write.mode("overwrite").parquet(f"{local_curated_path}tb_incidence.parque
t")

```

3.3.2 Data Cleaning

Penggabungan kelima dataset dilakukan secara berurutan menggunakan left join pada kunci (Entity, Year) dengan dataset insidensi TB sebagai tabel utama (base table). Pendekatan left join dipilih untuk memastikan semua observasi TB tetap dipertahankan meski data dari sumber lain tidak lengkap.

```

Python
from pyspark.sql.functions import col

def clean_dataset(df, year_start=2003, year_end=2022):
    return (df
        .filter((col("Year") >= year_start) & (col("Year") <= year_end))
        .filter(col("Code").isNotNull() & (col("Code") != ""))
        .dropDuplicates(["Entity", "Year"]))

```

3.3.3 Join Multi-Dataset

Penggabungan kelima dataset dilakukan secara berurutan menggunakan left join pada kunci (Entity, Year) dengan dataset insidensi TB sebagai tabel utama (base table). Pendekatan left join dipilih untuk memastikan semua observasi TB tetap dipertahankan meski data dari sumber lain tidak lengkap.

```

Python
from pyspark.sql.functions import col

```

```
base = tb_df.select("Entity", "Code", "Year",
    col("Estimated incidence of all forms of
tuberculosis").alias("tb_incidence"))

master_df = (base
    .join(gdp_df.select("Entity", "Year", col("GDP per
capita").alias("gdp_per_capita")),
        on=["Entity", "Year"], how="left")
    .join(health_df.select("Entity", "Year",
        col("Current health expenditure per capita
(int-$)").alias("health_expenditure"),
        col("Population").alias("population")),
        on=["Entity", "Year"], how="left")
    .join(pm25_df.select("Entity", "Year",
        col("`Annual PM2.5 emissions from
wildfires`").alias("pm25_emissions")),
        on=["Entity", "Year"], how="left")
    .join(popden_df.select("Entity", "Year",
        col("Population density").alias("pop_density")),
        on=["Entity", "Year"], how="left"))
```

3.3.4 Imputasi Nilai Kosong

Berdasarkan analisis awal, kolom `health_expenditure` memiliki 6,2% nilai kosong, tertinggi di antara semua fitur. Strategi imputasi yang digunakan adalah median per negara (bukan median global), untuk menghormati perbedaan sistemik antar negara dalam hal pengeluaran kesehatan. Jika sebuah negara tidak memiliki satu pun nilai valid untuk suatu fitur, maka digunakan median regional berdasarkan kolom `World_region`.

Python

```
from pyspark.sql import Window
from pyspark.sql.functions import percentile_approx, when

win_country = Window.partitionBy("Entity")
win_region = Window.partitionBy("World_region")

master_df = master_df.withColumn(
    "health_expenditure",
    when(col("health_expenditure").isNull(),
        percentile_approx("health_expenditure", 0.5).over(win_country))
    .otherwise(col("health_expenditure")))
```


3.3.5 Feature Engineering

Setelah data bersih dan tergabung, dilakukan rekayasa fitur untuk meningkatkan daya prediksi model. Fitur-fitur yang dihasilkan dikelompokkan ke dalam tiga kategori sebagai berikut.

Fitur Sosio-Ekonomi meliputi `gdp_per_capita` (GDP per kapita dalam USD PPP), `health_expenditure` (pengeluaran kesehatan per kapita), dan `health_gdp_ratio` yang dihitung sebagai rasio pengeluaran kesehatan terhadap GDP per kapita untuk menangkap efisiensi alokasi anggaran kesehatan.

Fitur Lingkungan dan Demografis meliputi `pm25_emissions` (total emisi PM2.5 dari kebakaran hutan), `pop_density` (kepadatan penduduk per km²), dan `population` (jumlah absolut penduduk). Variabel `log_pm25` dan `log_pop_density` ditambahkan sebagai transformasi logaritmik untuk menangani distribusi yang sangat miring (right-skewed).

Fitur Temporal meliputi `tb_lag1` dan `tb_lag2`, yaitu nilai insidensi TB satu dan dua tahun sebelumnya, yang dimasukkan sebagai fitur autoregresif untuk menangkap inersia epidemiologis. Selain itu, fitur `year_trend` (tahun dinormalisasi antara 0 dan 1) digunakan untuk menangkap tren sekuler jangka panjang.

```
Python
from pyspark.sql.functions import log1p, lag
from pyspark.sql import Window

win_ts = Window.partitionBy("Entity").orderBy("Year")

master_df = (master_df
    .withColumn("health_gdp_ratio", col("health_expenditure") /
col("gdp_per_capita"))
    .withColumn("log_pm25", log1p(col("pm25_emissions")))
    .withColumn("log_pop_density", log1p(col("pop_density")))
    .withColumn("tb_lag1", lag("tb_incidence", 1).over(win_ts))
    .withColumn("tb_lag2", lag("tb_incidence", 2).over(win_ts))
    .withColumn("year_trend", (col("Year") - 2003) / 19.0))
```

Seluruh fitur numerik kemudian dinormalisasi menggunakan `StandardScaler` dari Spark MLlib sebelum dimasukkan ke dalam model.

3.4 Metode analisis/model

3.4.1 Pembagian Data Latih dan Uji

Data dibagi berdasarkan dimensi waktu (temporal split) untuk menghindari kebocoran informasi (data leakage): data tahun 2003–2018 digunakan sebagai data latih ($\approx 80\%$) dan data tahun 2019–2022 digunakan sebagai data uji ($\approx 20\%$). Pendekatan temporal split lebih tepat dibandingkan random split untuk data deret waktu karena model harus diuji kemampuannya memprediksi masa depan, bukan menginterpolasi masa lalu.

3.4.2 Model Machine Learning

Tiga model machine learning diimplementasikan menggunakan Spark MLlib untuk dibandingkan performanya:

Random Forest Regressor dipilih sebagai model baseline karena kemampuannya menangani hubungan non-linear dan ketahanannya terhadap outlier. Model dilatih dengan 100 pohon dan kedalaman maksimal 10, dengan feature importance diekstraksi untuk interpretasi model.

Gradient Boosted Trees (GBT) dipilih sebagai model utama berdasarkan temuan Mariyam et al. (2025) yang menunjukkan performa lebih tinggi pada data epidemiologi TB. Model dilatih dengan 50 iterasi boosting dan learning rate 0,1.

Linear Regression digunakan sebagai pembanding statistik konvensional untuk mengkuantifikasi peningkatan performa yang diberikan oleh pendekatan ensemble.

Python

```
from pyspark.ml.regression import RandomForestRegressor, GBRegressor,
LinearRegression
from pyspark.ml.feature import VectorAssembler, StandardScaler
from pyspark.ml import Pipeline

feature_cols = ["gdp_per_capita", "health_expenditure", "health_gdp_ratio",
                "log_pm25", "log_pop_density", "population",
                "tb_lag1", "tb_lag2", "year_trend"]

assembler = VectorAssembler(inputCols=feature_cols, outputCol="features_raw")
scaler     = StandardScaler(inputCol="features_raw", outputCol="features")
rf_model   = RandomForestRegressor(featuresCol="features",
labelCol="tb_incidence",
                                numTrees=100, maxDepth=10)
gbt_model  = GBRegressor(featuresCol="features", labelCol="tb_incidence",
                        maxIter=50, stepSize=0.1)
```

```
pipeline_rf = Pipeline(stages=[assembler, scaler, rf_model])  
pipeline_gbt = Pipeline(stages=[assembler, scaler, gbt_model])
```

3.4.3 Metrik Evaluasi

Performa model dievaluasi menggunakan tiga metrik utama: RMSE (Root Mean Squared Error) untuk mengukur rata-rata besaran kesalahan prediksi dalam satuan yang sama dengan variabel target (kasus per 100.000 penduduk), R^2 (Coefficient of Determination) untuk mengukur proporsi variabilitas insidensi TB yang dapat dijelaskan oleh model (target $\geq 0,80$), dan MAE (Mean Absolute Error) untuk mengukur rata-rata kesalahan absolut yang lebih robust terhadap outlier.

Selain metrik regresi, model juga dievaluasi kemampuannya dalam mengklasifikasikan wilayah ke dalam tiga zona risiko: risiko tinggi (insidensi prediksi ≥ 150 kasus per 100.000 penduduk), risiko sedang (50–149 kasus), dan risiko rendah (< 50 kasus), menggunakan precision, recall, dan F1-score per kelas.

3.4.4 Interpretasi Model dan Output Kebijakan

Fitur-fitur dengan kontribusi prediksi tertinggi (feature importance) dari model terbaik akan diidentifikasi dan divisualisasikan sebagai dasar rekomendasi kebijakan. Hasil prediksi model kemudian dipetakan ke dalam peta risiko berbasis wilayah menggunakan pustaka geospasial, yang menampilkan gradasi zona risiko TB secara visual untuk mendukung pengambilan keputusan alokasi sumber daya kesehatan nasional.

Desain Eksperimen (*Experimental Design*)

4.1 Skenario Eksperimen

Dalam penelitian ini, pembagian data dilakukan menggunakan pendekatan *temporal split* untuk memastikan model mampu melakukan prediksi di masa depan berdasarkan data historis yang ada. Data dari tahun 2003 hingga 2018 dialokasikan sebagai *training set* untuk melatih model dalam mengenali pola kaitan antara faktor lingkungan dan risiko tuberkulosis (TB).

Sementara itu, data dari tahun 2019 hingga 2022 dijadikan *testing set* untuk menguji akurasi model. Penggunaan data pada rentang tahun terakhir ini bertujuan untuk menguji apakah model tetap akurat meskipun terdapat fluktuasi data akibat kondisi global yang tidak menentu dalam beberapa tahun belakangan.

4.2 Baseline / Model Pembanding

Untuk mengukur performa algoritma *Gradient Boosted Trees* (GBT) yang diusulkan, dua model standar diterapkan sebagai pembanding (*baseline*):

1. Linear Regression (LR): Digunakan sebagai model dasar yang paling sederhana untuk mengidentifikasi ada atau tidaknya hubungan linear antar variabel.
2. Random Forest Regressor (RF): Digunakan untuk membandingkan performa antar algoritma berbasis *tree* (*decision tree*) dalam menangani data yang berukuran besar dan kompleks.

Perbandingan ini dirancang untuk melihat apakah penerapan GBT di dalam lingkungan Apache Spark memberikan peningkatan akurasi dan efisiensi waktu pemrosesan yang signifikan dibandingkan model lainnya.

4.3 Lingkungan Eksperimen

Eksperimen ini dirancang untuk dijalankan pada lingkungan sistem operasi berbasis Linux dengan spesifikasi perangkat lunak sebagai berikut:

Tabel 4.1 *Spesifikasi Environment Eksperimen*

ID	Komponen	Spesifikasi
1	Sistem Operasi	Manjaro Linux (KDE Plasma)
2	Bahasa Pemrograman	Python3
3	Framework Big Data	Apache Spark (PySpark)
4	Infrastruktur Data	Hadoop HDFS (untuk penyimpanan dataset)
5	Library Utama	Spark MLlib, Pandas, Matplotlib

4.4 Metrik Evaluasi

Beberapa metrik standar yang digunakan untuk mengevaluasi model prediksi ini meliputi:

1. Root Mean Squared Error (RMSE): Berfungsi untuk mengukur seberapa besar rata-rata tingkat kesalahan prediksi dari model. Semakin kecil nilai RMSE, maka model dianggap semakin baik.
2. R-Squared (R^2): Digunakan untuk mengukur sejauh mana variabel independen (seperti faktor iklim dan ekonomi) mampu menjelaskan variasi pada risiko kejadian TB.
3. Mean Absolute Error (MAE): Menjadi metrik tambahan untuk melihat rata-rata selisih absolut antara hasil prediksi yang dihasilkan model dengan data yang sebenarnya.

Melalui ketiga metrik ini, evaluasi terhadap performa model dapat dilakukan secara lebih objektif dan komprehensif.

Hasil Eksperimen dan Analisis

5.1 Hasil Prapemrosesan dan Integrasi Data

Proses *data ingestion* pada arsitektur *Big Data pipeline* berhasil mengekstraksi total 102.266 baris data mentah yang berasal dari tiga sumber utama: IHME-GBD 2023 (18.450 baris), data PDB Per Kapita dari Bank Dunia (7.240 baris), dan Kepadatan Penduduk dari UN OWID (76.576 baris). Untuk memastikan relevansi fitur, penyaringan diterapkan pada dataset IHME, menghasilkan 6.150 baris data beban penyakit (TB) yang difungsikan sebagai tabel dasar (*base table*).

Integrasi data dilakukan melalui operasi *Left Join* pada kunci (negara, tahun), yang menghasilkan *master dataset* sebesar 6.150 baris. Pada tahap ini, teridentifikasi adanya nilai kosong (*missing values*) sebanyak 2.454 baris pada fitur *gdp_per_capita* dan 2.318 baris pada fitur *pop_density*. Penanganan anomali ini diselesaikan menggunakan metode imputasi median terdistribusi melalui Spark MLlib, yang secara sukses mereduksi nilai kosong menjadi nol (0) dan menghasilkan data *curated* yang siap diproses ke tahap pemodelan.

5.2 Evaluasi Kinerja Model Prediksi

Evaluasi kapabilitas prediktif dilakukan menggunakan pembagian data berbasis waktu (*temporal split*) guna mencegah kebocoran informasi (*data leakage*). Data historis hingga tahun 2022 dialokasikan sebagai data latih (5.424 baris), sedangkan data setelah tahun 2022 difungsikan sebagai data uji (726 baris).

Berdasarkan pengujian pada algoritma *Random Forest Regressor*, model mencatatkan kinerja yang sangat mumpuni dalam menangkap varians data. Hasil perhitungan metrik regresi menghasilkan skor Koefisien Determinasi (R^2) sebesar 0.9727 (97.27%). Model ini juga mencatatkan tingkat *Root Mean Squared Error* (RMSE) sebesar 1554.2673 dan *Mean Absolute Error* (MAE) sebesar 802.8105. Tingkat akurasi yang mendekati sempurna ini memvalidasi hipotesis bahwa integrasi indikator multi-dimensi secara signifikan meningkatkan presisi prediksi insidensi Tuberkulosis global.

5.3 Klasifikasi Zona Risiko Tuberkulosis

Guna memetakan tingkat kerentanan wilayah, segmentasi dilakukan menggunakan algoritma *Bisecting K-Means Clustering* dengan parameter $K=3$. Evaluasi klastering menghasilkan *Silhouette Score* sebesar 0.5456, yang mengindikasikan bahwa pembentukan klaster terdistribusi dengan cukup baik.

Pada implementasi prediksi terhadap data uji, wilayah terklasifikasi ke dalam tiga zona dengan distribusi: Zona Rendah (237 data), Zona Sedang (238 data), dan Zona Tinggi (251 data). Hasil pemrosesan juga mengekstraksi 10 wilayah dengan risiko TB tertinggi secara global, di mana negara-negara seperti Kiribati, Afrika Selatan, dan

Tuvalu menempati posisi teratas. Indonesia, dengan rasio prevalensi dan tingkat mortalitas yang diproses dalam model, secara definitif terklasifikasi ke dalam klaster Risiko Tinggi.

5.4 Analisis Signifikansi Fitur (*Feature Importance*)

Ekstraksi metrik *feature importance* dari model *Random Forest* yang telah dilatih menunjukkan bahwa setiap dimensi data memberikan tingkat kontribusi yang berbeda terhadap prediksi insidensi Tuberkulosis. Analisis terhadap bobot fitur menghasilkan distribusi signifikansi sebagai berikut:

- Beban Penyakit Historis (val_IHME_GBD) - 66,28%: Atribut ini merupakan prediktor paling dominan. Hal ini mengonfirmasi inersia epidemiologis, di mana wilayah dengan rekam jejak kasus TB historis yang tinggi memiliki kecenderungan paling kuat untuk mempertahankan tingkat insidensi di masa depan.
- Kepadatan Penduduk (pop_density) - 20,32%: Kepadatan populasi menempati urutan kedua sebagai faktor pemicu penyebaran. Selaras dengan literatur epidemiologi, kepadatan populasi mempercepat laju transmisi patogen melalui udara di wilayah urban maupun rural.
- PDB Per Kapita (gdp_per_capita) - 13,40%: Faktor sosio-ekonomi terbukti memiliki peran yang terukur dalam memprediksi risiko penyakit. Kapasitas ekonomi suatu negara memengaruhi aksesibilitas populasi terhadap layanan kesehatan preventif dan kuratif.

5.5 Pemetaan Spasial dan Rekomendasi Kebijakan

Hasil klasifikasi zona risiko dan nilai prediksi regresi telah diekspor ke dalam format *Comma Separated Values* (CSV) (hasil_prediksi_tb.csv) yang terstruktur untuk divisualisasikan melalui sistem informasi geospasial. Keluaran (*output*) ini menyediakan fondasi analitik preskriptif bagi pemangku kebijakan kesehatan. Dengan teridentifikasinya klaster wilayah risiko tinggi, alokasi sumber daya medis—seperti distribusi logistik pengobatan dan kampanye pencegahan—dapat difokuskan secara lebih efisien dan tepat sasaran pada wilayah-wilayah dengan kerentanan maksimal.

Kesimpulan dan Saran

6.1 Kesimpulan

Penelitian ini berhasil merancang dan mengimplementasikan arsitektur Big Data pipeline end-to-end berbasis Apache Spark untuk memprediksi risiko insidensi Tuberkulosis secara global. Beberapa poin utama yang dapat disimpulkan:

a. Keberhasilan Integrasi Data Multi-Sumber

Pipeline berhasil mengintegrasikan lima dataset heterogen dari WHO, World Bank, dan UN (total 102.266 baris mentah) mencakup 197 negara selama rentang 2003–2022. Proses imputasi median terdistribusi via Spark MLlib berhasil menghilangkan seluruh nilai kosong, menghasilkan master dataset sebesar 6.150 baris yang siap dimodelkan.

b. Performa Model yang Sangat Baik

Model Random Forest Regressor mencapai $R^2 = 0,9727$ (97,27%), membuktikan bahwa fusi fitur multi-dimensi — sosio-ekonomi, lingkungan, dan geografis — secara signifikan meningkatkan akurasi prediksi insidensi TB dibandingkan pendekatan konvensional berbasis variabel tunggal.

c. Klasifikasi Zona Risiko Global

Algoritma Bisecting K-Means ($K=3$) berhasil mengklasifikasikan wilayah ke dalam tiga zona risiko dengan Silhouette Score 0,5456. Negara-negara seperti Kiribati, Afrika Selatan, dan Tuvalu teridentifikasi sebagai zona risiko tertinggi, sementara Indonesia secara definitif masuk kluster Risiko Tinggi, konsisten dengan data WHO yang menempatkan Indonesia sebagai negara beban TB tertinggi kedua di dunia.

d. Feature Importance yang Bermakna

Tiga fitur paling dominan dalam model adalah beban penyakit historis (66,28%), kepadatan penduduk (20,32%), dan PDB per kapita (13,40%). Temuan ini mengonfirmasi bahwa inersia epidemiologis dan kondisi sosio-ekonomi adalah determinan utama penyebaran TB, bukan hanya faktor klinis.

e. Pengisian Research Gap

Penelitian ini menutup celah yang ada dalam literatur sebelumnya, yakni ketiadaan pipeline skalabel yang memfusi data sosio-ekonomi, lingkungan, dan geografis sekaligus dalam satu ekosistem komputasi terdistribusi untuk prediksi TB skala global.

6.2 Saran

a. Penambahan Data Nasional Indonesia

Integrasi data dari SITB Kementerian Kesehatan dan BPS hingga tingkat kabupaten/kota perlu diprioritaskan, mengingat masalah underreporting 41% yang masih menjadi kendala utama akurasi model untuk konteks kebijakan lokal.

b. Peningkatan Kualitas Klustering

Silhouette Score 0,5456 menunjukkan kualitas klaster yang belum optimal. Disarankan mengeksplorasi metode klasterisasi lain seperti HDBSCAN atau menambahkan fitur tambahan seperti data koinfeksi TB-HIV untuk meningkatkan separabilitas antar zona risiko.

c. Pengembangan Dashboard Kebijakan Interaktif

Output prediksi yang masih berupa file CSV perlu dikembangkan menjadi dashboard geospasial interaktif agar hasil model dapat langsung dimanfaatkan oleh pemangku kebijakan dalam pengambilan keputusan alokasi sumber daya kesehatan secara efisien.

Referensi

- [1] World Health Organization, *Global Tuberculosis Report 2024*, WHO, 2024.
- [2] The Lancet Respiratory Medicine, “Tuberculosis in Indonesia: challenges and future directions,” 2025.
- [3] World Health Organization, “The Second National TB Inventory Study in Indonesia,” 2024.
- [4] A. Author et al., “A Comprehensive Study on Tuberculosis Prediction Models,” *ScienceDirect*, 2024.
- [5] X. Author et al., “Epidemic-guided Deep Learning for Spatiotemporal Forecasting of TB Outbreak,” *arXiv*, 2025.
- [6] Author et al., “Prediction of TB Treatment Outcomes in Indonesia,” *JAIC*, 2025.
- [7] Author et al., “Design and Development of a Big Data Platform for Disease Burden Based on Spark Engine,” *PMC*, 2023.
- [8] Author et al., “Efficient Processing of Large-Scale Medical Data Using Hybrid Hadoop-Spark,” *IJACSA*, 2024.
- [9] Y. Tang, et al., “Machine learning prediction model of tuberculosis incidence based on meteorological factors and air pollutants,” *International Journal of Environmental Research and Public Health*, vol. 20, no. 5, 2023.
- [10] H. Mariyam, et al., “A comprehensive study on tuberculosis prediction models: Integrating machine learning into epidemiological analysis,” *Journal/Publisher (ScienceDirect)*, 2025.
- [11] H. M. Wolde, W. Kebede, D. Yewhalaw, G. Abebe, Y. Bae, and S. W. Lee, “Machine learning approaches to predict the risk of tuberculosis among household contacts of index TB patients in Central Ethiopia,” *Scientific Reports*, vol. 16, 2026.
- [12] G. Amany, S. Hashmi, J. S. Stow, P. Tumwesigye, B. Nkhata, K. R. Mubiru, A.-L. Budts, M. G. Potgieter, S. D. Balcha, M. Bamuloba, A. Zitho, L. Henry, M. G. Nabukenya-Mudiope, and C. Van Cauwelaert, “AI-driven tuberculosis hotspot mapping to optimize active case-finding: Implementing the Epi-control platform in Uganda,” *Tropical Medicine and Infectious Disease*, vol. 11, no. 36, 2026.

Lampiran


A. Tabel Kontribusi Anggota

No.	Nama — NIM	Bagian yang Dikerjakan	Kontribusi (%)
1	Danar Prayogo — 123140015	Implementasi kode program utama, penyusunan materi dan pelaksanaan Presentasi Progres 2, serta pengembangan kode pemrosesan data untuk model pipeline big data.	14%
2	Memory Simajuntak — 123140095	Analisis karakteristik dataset, pelaksanaan prapemrosesan data awal, pengembangan kode pemrosesan pipeline, serta penyusunan materi dan pelaksanaan Presentasi Progres 3.	15%
3	Refi Ikhsanti — 123140126	Pencarian dan analisis kelayakan dataset multi-sumber, penentuan topik penelitian kelompok, serta penyusunan materi dan pelaksanaan Presentasi Progres 1.	14%
4	Gohan Tua J. Ambarita — 123140160	Penyusunan materi dan pelaksanaan Presentasi Progres 2, perbaikan struktur kode program akhir, serta perancangan visualisasi data prediksi.	14%
5	Nadya Shafwah Yusuf — 123140167	Implementasi kode program utama, pelaksanaan prapemrosesan data awal, pengembangan kode pemrosesan pipeline, serta penyusunan materi dan pelaksanaan Presentasi Progres 3.	15%
6	Taufik Hidayat NST — 123140188	Pencarian dan analisis kelayakan dataset multi-sumber, penyusunan materi dan	14%

		pelaksanaan Presentasi Progres 1, serta perancangan visualisasi data prediksi akhir.	
7	Bonifasius Ezra Mariano — 123140196	Implementasi kode program utama, penyusunan materi dan pelaksanaan Presentasi Progres 2, serta pengembangan kode pemrosesan data untuk model pipeline big data.	14%
		TOTAL	100%

B. Visualisasi Data

 Peta Klasifikasi Kualitatif Cluster Risiko DALYs TB Global (Mode Peta 2D Datar — Murni Spark Kelompok 1)



C. Link Repository Github

Github : <https://github.com/nadshafy/BigData-Project-TBC>

D. Screenshot Hasil Kode

```

✓ Apache Spark 3.5.0 berhasil diinisialisasi!

=====
LAYER 1: DATA INGESTION
=====

📁 Hasil Ingestion:
  IHME (2 file) : 18,450 baris
  GDP per Capita : 7,240 baris
  Population Density: 76,576 baris
  Total data masuk : 102,266 baris

=====
LAYER 2: DATA LAKE
=====

✓ Data tersimpan ke Data Lake zona RAW:
  📁 datalake/raw/ihme_tb/
  📁 datalake/raw/gdp/
  📁 datalake/raw/pop_density/
✓ Data berhasil dibaca kembali dari Data Lake zona RAW!

=====
LAYER 3: PREPROCESSING
=====

📁 IHME setelah filter 'Laju': 6,150 baris
✓ Mapping nama negara selesai.
✓ GDP diproses. Kolom: GDP per capita
✓ Population Density diproses. Kolom: Population density

JOIN MULTI-DATASET (Left Join)

📁 Hasil Join:
  IHME (base) : 6,150 baris
  Master (join) : 6,150 baris
  id Indonesia : 34 baris

IMPUTASI MEDIAN (Spark MLlib)

📁 Missing values sebelum imputasi:
+-----+
|val|gdp_per_capita|pop_density|
+-----+
| 0|          2454|        2318|
+-----+

📁 Missing values setelah imputasi:
+-----+
|val|gdp_per_capita|pop_density|
+-----+
| 0|           0|           0|
+-----+

✓ Data curated tersimpan: 6,150 baris
  📁 datalake/curated/master/

```

```

PS D:\5_KOM\SEMESTER V\Big Data\TBC_Project> & "C:\Users\Memory_Sinarjuntak\AppData\Local\Programs\Python\Python311\python.exe" BigData.py
=====
LAYER 4A: BISECTING K-MEANS CLUSTERING (K=3)
=====
Training Bisecting K-Means...
Clustering selesai!

Jumlah cluster unik: 3

=====
EVALUASI CLUSTERING - SILHOUETTE SCORE
=====
Silhouette Score : 0.5456
Interpretasi : Cluster cukup baik (0.50-0.69)
=====

Statistik per Cluster:
-----+-----+-----+-----+
|country_cluster|profil_negara|    avg_tb_rate|    avg_gdp|    avg_pop_density|
-----+-----+-----+-----+
|0[Risiko Rendah]|462.6936163685354|14236.464457499327|116.09774693665436|
|1[Risiko Sedang]|380.6274889947264|58166.49186865336|432.9242784135449|
|2[Risiko Tinggi]|22869.4485798539828|14480.469948366126|122.81869730478946|
-----+-----+-----+-----+

Distribusi data per Cluster:
-----+-----+-----+
|country_cluster|profil_negara|count|
-----+-----+-----+
|0[Risiko Rendah]|4687|
|1[Risiko Sedang]|839|
|2[Risiko Tinggi]|1224|
-----+-----+-----+

=====
LAYER 4B: TRAINING MODEL RANDOM FOREST
=====

Temporal Split:
Split Year      : 2022
Training (<=2022) : 5,424 baris
Testing (>2022)  : 726 baris

Training Random Forest... (mohon tunggu)
Training selesai!
Prediksi pada test set...
WARNING: An illegal reflective access operation has occurred
WARNING: Illegal reflective access by org.apache.spark.util.SizeEstimator$ (file:/C:/Users/Memory_Sinarjuntak/AppData/Local/Programs/Python/Python311/Lib/site-packages/pyspark/jars/spark-core_2.12-3.5.0.jar) to field java.nio.charset.Charset.name
WARNING: Please consider reporting this to the maintainers of org.apache.spark.util.SizeEstimator$
WARNING: Use --illegal-access=warn to enable warnings of further illegal reflective access operations
WARNING: All illegal access operations will be denied in a future release
Prediksi selesai!

=====
LAYER 5: EVALUASI MODEL
=====

=====
HASIL EVALUASI RANDOM FOREST REGRESSOR
=====
R-Squared (R²) : 0.9727 (97.27%)
RMSE           : 1554.2073
MAE            : 802.8165
=====

```

DATASET (Multi-Sumber)

IHME-GBD 2023 : TB Rate per 100.000 pddk (target)
 World Bank (OWID) : GDP per Kapita (prediktor sosio-ekonomi)
 UN (OWID) : Kepadatan Penduduk (prediktor demografis)
 Total Ingestion : 102,266 baris

JOIN : Left Join pada kunci (negara, tahun)
 Master dataset: 6,150 baris

CLUSTERING : Bisecting K-Means (K=3)
 Fitur : GDP, Kepadatan, TB Rate, Tahun
 Silhouette Score = 0.3672

MODEL : Random Forest Regressor (50 trees)
 SPLIT : Temporal (<=2022 train | >2022 test)
 Training : 5,424 baris
 Testing : 726 baris

EVALUASI MODEL (Apache Spark MLlib)

R² : 0.9355 (93.55%)
 RMSE : 2389.1906
 MAE : 1542.7856

```
PS D:\S.KOM\SEMESTER VI\Big Data\TBC_Project> & "C:\Users\Memory_Sinarjuntak\AppData\Local\Programs\Python\Python311\python.exe" BigData.py

Batas Zona Risiko:
Rendah : prediksi ≤ 281.12
Sedang : 281.12 < prediksi ≤ 694.63
Tinggi : prediksi > 694.63

Distribusi Zona Risiko:
+-----+
|cluster_risiko|count|
+-----+
|      Rendah|  237|
|      Sedang|  238|
|      Tinggi|  251|
+-----+

10 Negara dengan Risiko TB Tertinggi:
+-----+-----+-----+-----+-----+
|translated_location|profil_negara|year|val|prediction|cluster_risiko|
+-----+-----+-----+-----+-----+
|Kiribati| [Risiko Tinggi]|2023|41588.40973986475|34185.96789844108|Tinggi|
|South Africa| [Risiko Tinggi]|2023|44059.62182002664|34076.13584617221|Tinggi|
|Tuvalu| [Risiko Tinggi]|2023|35787.02662221996|33994.94894290853|Tinggi|
|Vietnam| [Risiko Tinggi]|2023|42598.76321559213|33721.16695401816|Tinggi|
|Marshall Islands| [Risiko Tinggi]|2023|38492.08521725105|33551.72343478072|Tinggi|
|Nauru| [Risiko Tinggi]|2023|34701.62367743319|33501.46960006894|Tinggi|
|Vanuatu| [Risiko Tinggi]|2023|37394.27695482428|32960.13110047533|Tinggi|
|Indonesia| [Risiko Tinggi]|2023|36218.06050998641|32907.14104312636|Tinggi|
|Papua New Guinea| [Risiko Tinggi]|2023|37344.66374651122|32877.92183175133|Tinggi|
|Fiji| [Risiko Tinggi]|2023|35605.14539624141|32581.189970740747|Tinggi|
+-----+-----+-----+-----+-----+
only showing top 10 rows

=====
ANALISIS KHUSUS: INDONESIA
=====

Prediksi vs Aktual TB -- Indonesia (4 baris):
+-----+-----+-----+-----+-----+-----+-----+-----+
|translated_location|year|measure_name|val|prediction|cluster_risiko|gdp_per_capita|pop_density|profil_negara|
+-----+-----+-----+-----+-----+-----+-----+-----+
|Indonesia| 2023|Prevalensi|36218.06050998641|32907.14104312636|Tinggi|13889.975|148.57692|Risiko Tinggi|
|Indonesia| 2023|Meninggal|24.97067255745465|244.4646281830741|Rendah|13889.975|148.57692|Risiko Rendah|
|Indonesia| 2023|Insidensi|158.28938777096|269.83084999610134|Rendah|13889.975|148.57692|Risiko Rendah|
|Indonesia| 2023|DALYs (Disability-Adjusted Life Years)|1086.4830466615495|786.689142556006|Rendah|13889.975|148.57692|Risiko Rendah|
+-----+-----+-----+-----+-----+-----+-----+-----+

Indonesia → Zona Risiko: Tinggi

=====
LAYER 5: VISUALISASI (matplotlib)
=====
Visualisasi tersimpan: D:\S.KOM\SEMESTER VI\Big Data\TBC_Project\hasil_evaluasi_tb.png

=====
OUTPUT CSV
=====
Output tersimpan:
  D:\S.KOM\SEMESTER VI\Big Data\TBC_Project\hasil_prediksi_tb.csv
  D:\S.KOM\SEMESTER VI\Big Data\TBC_Project\hasil_evaluasi_tb.csv
  D:\S.KOM\SEMESTER VI\Big Data\TBC_Project\hasil_evaluasi_tb.png
```